FairEval 论文复现中期进展

自然语言处理项目实践 2026　论文编号 P29　记录日期 2026 年 10 月 26 日

原文目标位置

Wang 等，ACL 2024，Large Language Models are not Fair Evaluators。Table 2（p.9442）比较回答前后位置的胜率；§2.3 提出 EC、MEC 与 BPC；Table 4（p.9445）的 Vanilla 和 MEC(k=3)+BPC(k=3)行、Accuracy 列是本组校准对照目标。

本组设置差异

采用 Qwen2.5-72B-Instruct 与非思考模式 Qwen3-32B 作 BF16 裁判，开展方法迁移验证及 P 位置、L 标签、S 指定评分行顺序的扩展。作者 80 题按本组固定划分为 20 校准、60 检验，另验证 LLMBar 70 题；检验题此前已查看。每题每模型 76 次，共 22,800 次，三区组采样均已完成，执行故障为 0。作者代码跳过失败评分，本组要求所需评分完整，484 次无效输出保留并计入严格评价。

已有并列结果

表 1 严格人工一致率或准确率（%，无效计错；FairEval 为 60 题，LLMBar 为 70 题，三区组按题汇总）。

评审器	检验数据	Vanilla	MEC3＋BPC3	B 双布局	D 八布局
72B	FairEval 60	56.59	63.33	60.00	57.22
72B	LLMBar 70	77.85	77.62	75.71	76.19
32B	FairEval 60	59.98	51.67	48.33	48.89
32B	LLMBar 70	81.59	74.76	69.52	67.62

72B 与 32B 指上述 Qwen 裁判。单次判决用量：Vanilla 为 1 次，MEC3＋BPC3 为正反各 3 次，B 为正反各 4 次，D 为八布局各 1 次。Vanilla 按预存 100 次方向分配复算，复用同批输出。设置和题集不同于原文，表内仅作本组方法比较。

Vanilla 正反顺序判决不一致率为 50.00%（72B）和 38.33%（32B），包含平局变化。预设主比较 72B / 60 题的 D−B 为−2.78 个百分点，题目配对 bootstrap 5,000 次的 95%区间为[−8.33，+2.22]；八布局的优势尚不明确，区间仍容许改善和退化。

两例失败或边界

FairEval-056，区组 1：人工为平局；B 分差 0、判平，D 分差+0.4375、改判 X。FairEval-067，区组 1：人工偏好 X；B 有一次评分后继续解释，末尾评分块不合规而整体无效；D 八次均有效、判 X。后一例的指标变化包含格式有效性的影响。案例分差均为 X−Y。

下一项单因素对照

在完整 24 格共同题集上固定 P 与 L，仅比较 S 正反，按题核对评分分差、平局转换及有效率，并以同布局重复波动作参照。所需调用已包含在八布局数据中；下一步复用既有输出，按冻结提示、划分及平局阈值完成逐题解释，无需新增生成。

逐条运行证据：https://github.com/steve1-git/faireval-midterm-2026/blob/main/evidence/README.md